

# 엣지/클라우드 컴퓨팅 기반 AWS DeepLens 를 이용한 모션 인식 및 실시간 스트리밍

경희대학교 최지우 이민규

## A. Abstract

최근 세계적으로 다양한 분야에서 비대면 커뮤니케이션으로의 전환이 이루어지고 있다. 하지만 직접 몸을 움직이거나 자세 교정이 필요한 실내 운동의 강좌는 비대면으로의 전환이 어려운 상황이다. 따라서 이 연구는 엣지 노드로 많이 활용되고 있는 AWS DeepLens 를 기반으로 실내 운동 모션의 인식과 실시간 스트리밍을 통해 강 의자와 수강생의 커뮤니케이션이 가능하도록 하는 서비스를 제안하고 구현한다.

## B. Introduction

### A. 연구 배경

최근 범세계적으로 지속되는 COVID-19 의 여파로, 외부활동을 자제하고 집에 머무는 시간이 많아지면서 비대면 서비스의 이용이 크게 증가하고 있다. 특히나 실시간 원격 화상 회의 또는 영상 시청의 이용이 많이 증가하여 관련 언택트 커뮤니케이션 서비스의 수요가 눈에 띄게 늘어났다.

일반적인 이론 강의는 비대면으로 실시간 화상 회의 또는 영상 시청을 통해 어느정도 대체가 가능하다. 하지만 태권도나 요가, 필라테스 등 트레이닝 교습 및 실내 운동시설은 정상적인 운영이 어려운 상황이다. 이러한 상황을 타개하기 위해, 엣지 노드로 많이 활용되고 있는 DeepLens 를 활용하여, 언택트 온라인 환경에서도 자세 교정이나 움직임이 중요한 실내 트레이닝 강의를 실시간 스트리밍 및 모션 인식 카메라를 통해 제공할 수 있도록 한다.

## B. Goal

기본적으로 AWS DeepLens 를 통해 실내 운동 모션의 실시간 영상 분석과 추론을 수행할 수 있어야 한다. 또한 실시간 영상을 타인과 공유할 수 있도록 라이브 스트리밍을 지원한다. 데이터 분석 결과는 사용자에게 즉각적으로 피드백을 제공할 수 있어야 하며, 실시간으로 영상을 공유하고 있는 다른 사용자와 결과를 공유할 수 있도록 한다.

## C. 관련 연구

### A. 모션 인식 게임



#### 1. Kinect

Microsoft 의 콘솔 게임기인 Xbox 360, Xbox One 에서 사용되는 주변기기이다. 피사체의 거리를 측정하여 1cm 단위로 인식하며, 움직임뿐만 아니라 표정, 최대 4 명의 인원 수, 음성까지 인식 가능하다. 별도의 컨트롤러 필요없이 온몸의 동작을 추적하여 게임을 즐길 수 있다. 하지만 Kinect 를 제대로 활용한 게임은 댄서의 동작을 보며 따라하는 JUST DANCE 시리즈정도 밖에 없었으며, 다층 구조의 인터페이스 제어가 어려웠기 때문에 게임용 Kinect 는 생산이 중지되었다. 하지만 PC 용 Kinect 는 USB 로 연결되며 별다른 부수기재가 필요 없기 때문에 저렴한 모션 캡처 기기로서 다양한 용도로 응용되고 있다.

#### 2. PlayStation 4 (PlayStation Camera)

2 개의 HD 카메라를 통해 컨트롤러의 움직임과 3D 공간에서 위치를 파악해 동작 인식 기능을 지원하는 PlayStation 4 전용 동작 인식 장치이다. 얼굴 인식 기능과 AR(증강현실)을 지원한다. Kinect 보다는 떨어지는 성능을 가지지만 기본적인 모션 인식은 가능하다.

## B. AWS DeepLens 를 이용한 모션 추적

AWS DeepLens 는 딥 러닝이 지원되는 비디오카메라로, 디바이스 자체에서 HD 비디오에 대한 기계 학습 모델을 실행하고 추론을 실시간으로 수행할 수 있다. Amazon Sagemaker 를 이용하여 개발자가 직접 모델을 훈련하거나, 동작이 발생할 때 Lambda 함수를 트리거함으로써 기능을 확장할 수 있다. 아래는 사람의 동작이나 자세를 인식하는 몇 가지 커뮤니티 프로젝트의 예시이다.



### 1. Exercise Counter

AWS DeepLens 카메라에서의 영상 스트리밍을 처리하여 벤치 프레스, 랫 풀 다운 등의 운동한 횟수를 카운트해주며, 모바일 또는 웹 앱을 통해 개인 통계를 표시해준다. Python 언어를 통해 작성되었으며, 운동에 대한 로그가 AWS IoT 를 통해 Lambda 로 전송되어 Elasticsearch 에 저장된다.

### 2. DeepLens 및 GluonCV 를 이용한 재택 근무 자세 추적기

AWS DeepLens 에서 GluonCV 모델(컴퓨터 비전 라이브러리의 일종)을 실행하여 의자에 앉아있는 자세를 감지하여 몸의 포인트를 맵핑하고 나쁜 자세를 감지할 때마다 메시지 알림을 보내는 서비스이다.

## C. Live Streaming

### 1. WebRTC

WebRTC 는 간단한 API 를 통해 브라우저, 모바일 어플리케이션에서 실시간 통신을 가능하게 하는 open technology 이다. Amazon Kinesis Video Streams 를 사용하여 영상을 라이브 스트리밍 하거나, 모바일 또는 웹 플레이어 간에 양방향 오디오, 비디오 상호 작용을 주고받을 수 있다


## 2. Google Meet

Google 이 제공하는 화상 회의 서비스이다. 실시간으로 개인의 오디오 및 비디오를 스트리밍 하여 비대면 커뮤니케이션이 가능하게 하는 live streaming 서비스이다. 쉬운 접근성과 다수의 인원이 동시에 안정적으로 접속할 수 있는 이점 덕분에, 실시간 비대면 강의, 미팅 등에 많이 사용된다.

## 3. Youtube Live

Youtube 에서 제공하는 실시간 라이브 스트리밍 서비스이다. 자신의 계정(채널)을 통하여 카메라(웹 캠, 모바일 카메라)를 통한 스트리밍이 가능하다. 그러나 양방향 동시 스트리밍이 아닌 일방향의 스트리밍 서비스를 제공하며, 채널의 구독자가 특정 수 이상이어야 서비스 이용이 가능하다는 제한 사항이 있다.

## D. 모션 인식 딥러닝 기반 요가수업 서비스 MIXPOSE



Mixpose 는 요가 자세와 관절의 움직임을 볼 수 있는 요가 동영상을 실시간으로 스트리밍해 수강생들이 요가 자세를 정확히 이해할 수 있도록 도와주는 요가 수업용 서비스이다. 클라이언트 컴퓨터 환경에서 Tensorflow PoseNet 를 이용한 몸의 위치

추정데이터를 분석하여 관절의 움직임을 보여주며 웹캠 및 카메라 악세사리와 WebRTC 를 이용하여 스트리밍을 제공한다.

## **D. 기존 연구의 문제점 및 해결 방안**

### **A. 기존 연구 분석 및 문제점**

기존에 카메라 모션 인식을 통해 실내 운동에 도움을 주는 서비스가 여럿 존재하지만, 네트워크를 통해 실시간으로 상황과 결과를 공유하거나 커뮤니케이션을 제공하는 서비스는 거의 없다. 단순히 개인의 화면을 보고 동작을 따라하는 것이 아닌, 영상을 실시간 스트리밍을 통해 타인과 커뮤니케이션을 하면서 동시에 모션 인식에 대한 피드백이 제공될 수 있어야 한다.

또한 새로운 데이터의 학습이나 데이터 세트의 업데이트가 즉각적으로 이루어지지 않아 클라이언트가 직접 환경을 업데이트할 필요가 있어 확장성과 경제성이 떨어진다. 따라서 클라우드 환경에서 어플리케이션을 초기 구축하고 SW 업그레이드를 진행함으로써 확장성, 보안성, 유연성을 극대화하는 것이 필요하다.

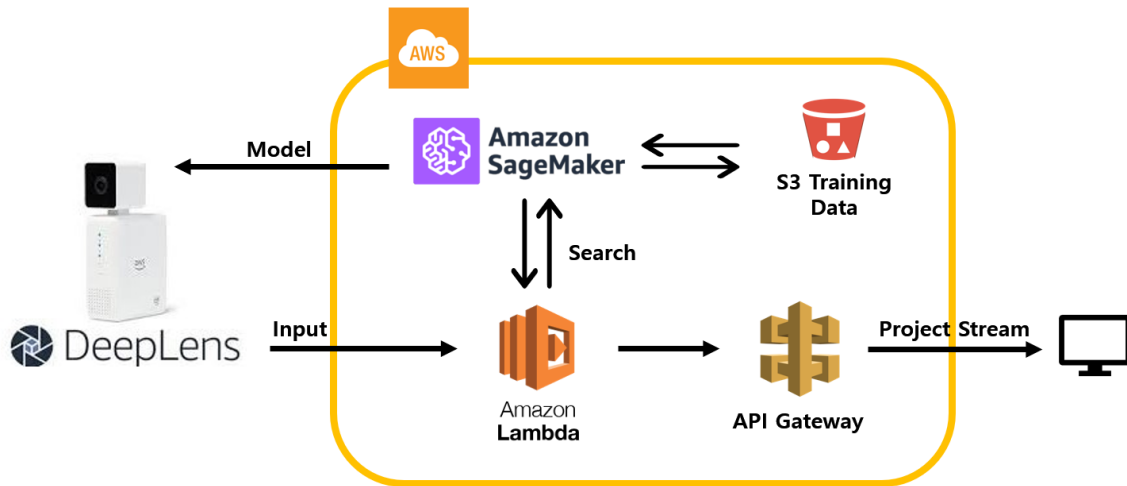
### **B. 해결 방안**

HD 비디오에 대한 딥러닝 예측을 실시간으로 처리할 수 있고, 장치에서 직접 카메라 스트리밍을 볼 수 있는 엣지 노드, AWS DeepLens 를 사용한다. 또한 클라우드를 활용한 대용량 데이터들을 수집해서 처리할 수 있는 기능을 제공하는 AWS 의 Amazon Sagemaker 를 통해 실내 운동에 관한 데이터를 직접 학습시켜 임포트한다.

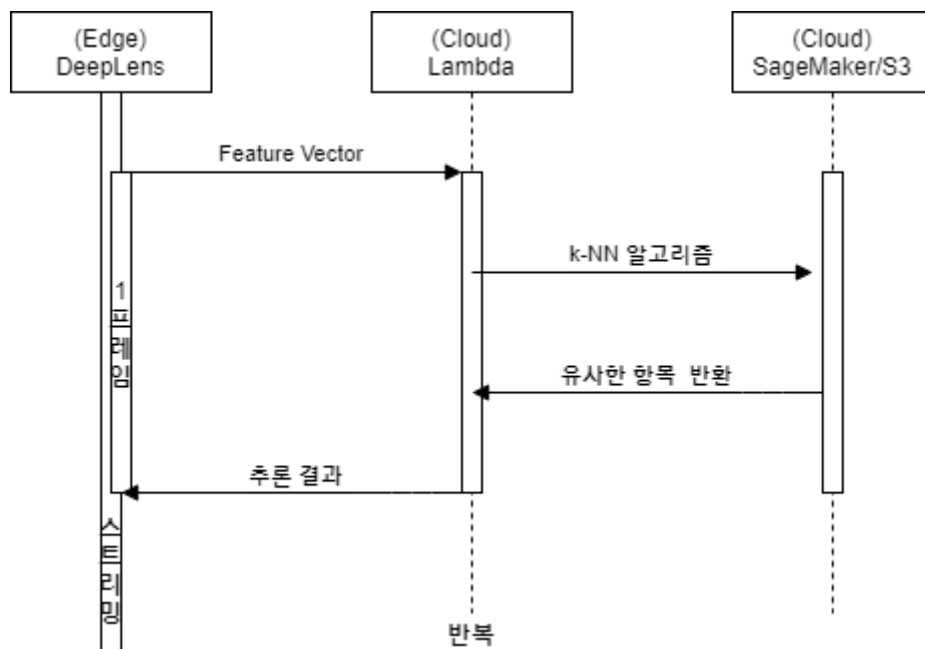
또한 동작이 발생할 때 데이터에 대한 피드백을 주는 Lambda 함수를 트리거하고, Amazon Kinesis Video Streams 를 통해 실시간으로 다른 사용자에게 영상을 공유하는 등 다른 AWS 서비스를 통합시켜 기능을 확장한다.

## E. Project Architecture

### A. Architecture Diagram



### B. Scenario



### C. Requirement

1. 스트리밍 및 일치성 출력

- AWS DeepLens 에서 출력되는 비디오를 Kinesis Video Streams 를 통해 웹 어플리케이션에 전달된다. DeepLens\_Kinesis\_Video 모듈이 AWS DeepLens 디바이스에 설치되어 있으며, 배포된 Lambda 함수에서 이 모듈을 호출할 수 있다.
- Stream.start 메서드와 Stream.stop 메서드를 통해 AWS DeepLens 디바이스의 비디오 피드에 대한 Kinesis 스트림을 캡슐화하고 데이터 스트리밍 시작 및 중지를 제어한다.
- 사용자들의 정보와 영상이 바둑판 배열 형태로 웹 페이지에 표시되도록 구현한다.
- 실시간 스트리밍 미팅의 기본적인 기능을 제공한다. (음성 대화, 음소거)
- 사용자의 모션이 AWS DeepLens 를 통해 실시간으로 인식되고, 동작이 발생할 때 Lambda 함수를 트리거함으로써 동시에 웹 페이지를 통해 결과를 공유할 수 있어야 한다.
- 각 사용자의 모션의 종류와 일치성을 공유하는 표를 화면 우측 단에 표시한다.

## 2. 실시간 모션 인식

- AWS DeepLens 가 사용자의 동작을 인식하면 장치는 해당 모션을 나타내는 Feature Vector 를 생성한다. 이를 얻기 위해서 DeepLens awscam.Model API 의 doInference 메소드를 호출해야 한다.
- 엣지 디바이스에서 생성된 Feature Vector 는 AWS 클라우드로 전송되며, AWS Lambda 함수로 지정하는 데 사용된다.
- 이 Search Lambda 함수는 Feature Vector 를 사용하여 Amazon SageMaker 에서 Amazon SageMaker k-Nearest Neighbors(k-NN) 알고리즘을 사용하여 유사한 항목을 검색하고, 반환하여 웹 어플리케이션에 전달된다.

## 3. 모션 모델링

- deeplens-sagemaker-<string>으로 지정된 Amazon S3 버킷 생성이 필요하다.
- SageMaker 의 notebookinstance 를 생성한다.
- 몇 가지 라이브러리를 설치한 후, 데이터를 셔플하여 훈련 데이터와 테스트 데이터로 나눈다. 데이터의 70%인 훈련 데이터는 모델 훈련 루프에서 사용되며, gradient 기반 최적화를 통해 오류를 최소화하는 모델 파라미터 값을 찾는다.

- 나머지 30%의 테스트 데이터는 모델의 성능을 평가하고 훈련된 모델의 데이터를 일반화하는 성능을 평가하는 데 사용된다.
- 모델을 학습시키기 위해서 PyTorch 프레임워크를 사용하여 작성한 스크립트를 통해 SageMaker 에서 모델을 교육하고 호스팅한다.

## F. 구현

### A. 이미지 크롤링 및 데이터 세트 가공

딥러닝 모델 학습을 위해 가장 먼저 필요한 것은 이미지 데이터 세트이다. 이미지 수집에는 google\_images\_download 라이브러리를 사용하였으며, Python 스크립트를 작성하여 이미지 크롤링을 진행하였다. 분류하고자 하는 각 라벨마다 약 200 장의 이미지를 수집하였다.

정교한 모델 학습을 위해 데이터 세트가 부족한 경우에는 이미지 변형을 통한 가공이 필요하다. 아래 코드와 같은 MXNet 을 이용한 Keras 라이브러리를 통해 이미지 데이터 세트 가공을 진행하였으며, 이미지 반전, 회전 등을 통해 각 라벨 별 약 650 장의 Train set 와 약 200 장의 Validation set 를 생성하여 대략 75:25 의 비율로 데이터 세트를 마련하였다.

이로써 모델 학습을 위한 이미지 데이터 세트가 마련되었으며, 데이터는 Train/Validation set 유형과 Label 분류에 맞춰 적절한 저장 경로를 설정해준다.

```
import numpy as np
import os
np.random.seed(3)
from keras.preprocessing.image import ImageDataGenerator, array_to_img, img_to_array, load_img
optInputPath = '~/yoga/'
optOutputPath = '~/preview/'

# 이미지 크기 조정 비율
optRescale = 1./255
# 이미지 회전
optRotationRange=10
# 이미지 수평 이동
```



```

optWidthShiftRange=0.2
# 이미지 수직 이동
optHeightShiftRange=0.2
# 이미지 밀림 강도
optShearRange=0.5
# 이미지 확대/축소
optZoomRange=[0.9,2.2]
# 이미지 수평 뒤집기
optHorizontalFlip = True
# 이미지 수직 뒤집기
optVerticalFlip = False
optFillMode='nearest'
# 이미지당 늘리는 갯수
optNbrOfIncreasePerPic = 3
# 배치 수
optNbrOfBatchPerPic = 2
train_datagen = ImageDataGenerator(rescale=optRescale,
                                    rotation_range=optRotationRange,
                                    width_shift_range=optWidthShiftRange,
                                    height_shift_range=optHeightShiftRange,
                                    shear_range=optShearRange,
                                    zoom_range=optZoomRange,
                                    horizontal_flip=optHorizontalFlip,
                                    vertical_flip=optVerticalFlip,
                                    fill_mode=optFillMode)

def checkFoler(path):
    try:
        if not(os.path.isdir(path)):
            os.makedirs(os.path.join(path))
    except OSError as e:
        if e.errno != errno.EEXIST:
            raise

def increaseImage(path ,folder):
    for index in range(0,optNbrOfIncreasePerPic):
        img = load_img(path)
        x = img_to_array(img)
        x = x.reshape((1,) + x.shape)
        i = 0
        checkFoler(optOutputPath+folder)
        print('index : ' + str(index))
        for batch in train_datagen.flow(x, batch_size=1,
save_to_dir=optOutputPath+folder, save_prefix='tri', save_format='jpg'):
            i += 1
            print(folder + " " + str(i))
            if i >= optNbrOfBatchPerPic:
                break

# 이미지 생성기
def generator(dirName):

```

```

checkFolder(optOutputPath)
try:
    fileNames = os.listdir(dirName)
    for fileName in fileNames:
        fullFileName = os.path.join(dirName, fileName)
        if os.path.isdir(fullFileName):
            generator(fullFileName)
        else:
            ext = os.path.splitext(fullFileName)[-1]
            folderName = os.path.splitext(fullFileName)[0].split('/')[2]
            if(ext == '.jpg'):
                increaseImage(fullFileName, folderName)

except PermissionError:
    pass
if __name__ == "__main__":
    generator(optInputPath)

```

### 3.2. Amazon SageMaker 를 통한 모델 학습

Amazon SageMaker 의 다양한 예제 코드 중 Image-Classification-FullTraining 을 사용한다. 이는 ResNet 네트워크를 사용하여 훈련되며, 객체를 식별할 수 있는 객체 분류 모델을 빌드한다.

먼저 데이터셋 가공을 통해 얻은 이미지 데이터 세트를 호스팅하는 버킷을 AWS S3 에서 정의한다. 버킷 이름에는 'deeplens'가 포함되어야 한다. 이 예제 코드에서는 Amazon SageMaker 의 기본 이미지 분류모델인 ResNet 을 사용하기 때문에, 이미지 데이터 세트를 .rec 형태의 확장자로의 변경이 필요하다. 이미지 파일을 rec 파일로 변환하기 위해서는 MXNet tool 함수 중 im2rec.py 를 사용한다. 이후 rec 파일을 경로에 맞춰 버킷에 업로드한다.

아래의 코드는 이미지 분류 모델 학습 프로세스 제어에 사용되는 하이퍼 파라미터 목록이다. num\_layers 를 통해 네트워크 깊이를 정의할 수 있다. ResNet 은 18, 34, 50 등 여러 네트워크 깊이를 지원하며, 초기값인 18 을 사용한다. image\_shape 는 입력 이미지의 크기이며, 224\*224 크기의 3 가지 색상(RGB)을 사용한다. num\_training\_samples 는 훈련할 데이터의 샘플 수로, 약 800 장의 이미지를 사용하였다.

num\_classes 는 모델의 출력 클래스 수로, 분류할 두 가지 자세와 '그 외의 이미지'를 분류하기 위해 3으로 설정한다. mini\_batch\_size는 한 번 반복에서 사용되는 학습 예제의 수이며, epochs 는 전체 데이터 세트가 네트워크에서 반복 처리될 횟수이다.

이후 코드에서 Amazon SageMaker 에서 모델을 훈련하기 위해 훈련 작업(JOB)이 생성된다. JOB 에는 이미지 데이터를 저장한 Amazon S3 버킷의 URL 과, 모델 교육에 사용할 컴퓨팅 리소스, 출력을 저장할 S3 버킷의 URL 정보가 포함된다. 모델 교육에 사용할 컴퓨팅 리소스의 기본 설정이 클라우드에서 가장 큰 GPU 지원 가상 머신인 p2.xlarge 이기 때문에, 일반 사용자는 문의를 통해 인스턴스 제한 변경을 요청하여야 한다. 작업 생성이 완료되면 CloudWatch 에서 로그 기록을 통해 학습 결과를 볼 수 있다. 이를 통해 AWS DeepLens 에 직접 가져올 수 있는 모델이 생성된다.

```
# 알고리즘에 사용되는 네트워크 깊이
```

```
num_layers = "18"
```

```
# 이미지 크기
```

```
image_shape = "3,224,224"
```

```
# 학습 이미지 샘플 수
```

```
num_training_samples = "1100"
```

```
# 분류할 라벨 수
```

```
num_classes = "3"
```

```
# 배치 사이즈
```

```
mini_batch_size = "64"
```

```
# 반복 수
```

```
epochs = "3"
```

```
# learning rate
```

```
learning_rate = "0.01"
```

```
# SageMaker 에 JOB 생성
```

```
sagemaker = boto3.client(service_name='sagemaker')
```

```
sagemaker.create_training_job(**training_params)
```

```
status =
```

```
sagemaker.describe_training_job(TrainingJobName=job_name) ['TrainingJobStatus']
```

```
print('Training job current status: {}'.format(status))
```

```
try:
```

```
sagemaker.get_waiter('training_job_completed_or_stopped').wait(TrainingJobName=job_name)
```

```
    training_info = sagemaker.describe_training_job(TrainingJobName=job_name)
```

```
    status = training_info['TrainingJobStatus']
```

```

print("Training job ended with status: " + status)
except:
    print('Training failed to start')
    message =
sagemaker.describe_training_job(TrainingJobName=job_name) ['FailureReason']
    print('Training failed with the following error: {}'.format(message))

training_info = sagemaker.describe_training_job(TrainingJobName=job_name)
status = training_info['TrainingJobStatus']
print("Training job ended with status: " + status)

```

### 3.3. DeepLens 모델 배포 및 Lambda 함수 설정

AWS DeepLens 콘솔에서 Amazon SageMaker 를 사용하여 훈련된 모델을 직접 가져오는 기능을 사용한다. DeepLens 버전이 1.2.3 이상 및 MXNet 버전 0.12 로 업데이트가 필요하다.

AWS DeepLens 기기를 콘솔에서 등록하는 작업이 필요하다. AWS 콘솔에서 설명하는 절차를 따라 등록이 완료되면, 새로운 빈 프로젝트를 생성한다.

[그림 5] AWS DeepLens Project 생성

위 그림과 같이 프로젝트 이름을 설정하고 Project content 에서 Add model 을 클릭하여 Amazon SageMaker trained model 을 선택하고, 이전의 과정에서 학습한 모델을 선택하여 가져온다. 모델이 추가되면 Add Function 를 선택하여 Lambda 함수를 추가하여야 한다. 아래는 AWS Lambda 콘솔을 사용하여 추론 Lambda 함수를 생성하는 과정이다.

딥러닝 모델에 대한 추론을 실행하는 Lambda 함수를 생성하기 위해 Create Function 을 진행하고, 블루프린트 사용을 선택하여 샘플 코드를 이용한다. greengrass-hello-world 샘플 코드를 사용하였으며, Lambda 함수에 모델과 동일한 이름을 지정한다.

함수에 대한 권한을 정의하는 역할 지정에서 AWSDeepLensLambdaRole 기본 IAM 역할을 선택한다. 함수 생성이 완료되면 핸들러가 greengrassHelloWorld.function\_handler 인지 확인하여야 한다. 이후 GreengrassHello 파일에서 모든 코드를 제거하고 추론 Lambda 함수에 대한 코드를 작성한다. Lambda 함수 작성이 완료되면 저장하여 배포, 게시한다. 이 Lambda 함수를 DeepLens 프로젝트에서 선택하여 추가하면 프로젝트 생성이 완료된다.

이로써 Edge 기기(DeepLens)에서 생성된 데이터를 이용하여 Cloud 서비스에서의 Serverless 한 함수 실행을 통한 딥러닝 모델 추론이 가능해진다.

```
while True:
    # 스트리밍 마지막 프레임 가져오기
    ret, frame = awscam.getLastFrame()
    if not ret:
        raise Exception('Failed to get frame from the stream')
    # 인식 범위를 위한 프레임 크롭
    frame_crop =
frame[
                                int(frame.shape[0]/2-
region_size/2):int(frame.shape[0]/2+region_size/2), \ int(frame.shape[1]/2-
region_size/2):int(frame.shape[1]/2+region_size/2), :]

    # 학습 데이터에 맞춘 프레임 크기 변경
    frame_resize = cv2.resize(frame_crop, (input_height, input_width))
    frame_resize = cv2.cvtColor(frame_resize, cv2.COLOR_BGR2RGB)
    parsed_inference_results = model.parseResult(model_type,
model.doInference(frame_resize))

    # 일치도가 가장 높은 라벨
    top_k = parsed_inference_results[model_type][0:num_top_k]

    # 프레임 복사
    overlay = frame.copy()
    cv2.rectangle(overlay, (0, 0),
                    \ (int(label_region_width),int(label_region_height)), (211,211,211), -1)
    opacity = 0.7
    cv2.addWeighted(overlay, opacity, frame, 1 - opacity, 0, frame)

    # 가장 높은 일치도를 가진 라벨에 따라 출력되는 메시지 변경
    if top_k[0]['prob']*100 < 60 :
        cv2.putText(frame, 'Take your pose', (0,50), cv2.FONT_HERSHEY_SIMPLEX,
                    1.5, (255, 0, 0), 3)
    else :
        cv2.putText(frame, output_map[top_k[0]['label']] + ' ' +
```

```

str(round(top_k[0]['prob'], 3) * 100) + '%', \ (0, 150), cv2.FONT_HERSHEY_SIMPLEX, 1.5,
(255, 0, 0), 3)

# 인식 범위 화면에 출력
cv2.rectangle(frame, (int(frame.shape[1]/2-region_size/2), int(frame.shape[0]/2-
region_size/2)), \
(int(frame.shape[1]/2+region_size/2), int(frame.shape[0]/2+region_size/2)), (255,0,0),
5)
local_display.set_frame_data(frame)
# MQTT 를 통해 IOT 로그 남김
cloud_output = {}
for obj in top_k:
    cloud_output[output_map[obj['label']]] = obj['prob']
    client.publish(topic=iot_topic, payload=json.dumps(cloud_output))
except Exception as ex:
    client.publish(topic=iot_topic, payload='Error : {}'.format(ex))

```

### 3.4. Live Streaming

프로젝트가 생성되면, DeepLens 콘솔의 Device 목록에서 등록된 기기를 선택하여 프로젝트를 Deploy 할 수 있다. Review 와 Deploy 가 완료되면, DeepLens 콘솔에서 Streaming 화면을 확인할 수 있다. AWS DeepLens 에는 Amazon Kinesis 비디오 스트림 통합을 위한 DeepLens\_Kinesis\_Video 모듈이 포함된다. 이 Python 모듈을 사용하면 DeepLens 기기에서 Kinesis 로 비디오 피드를 보내고 스트리밍을 제어할 수 있다. 모듈은 DeepLens 프로젝트에서 배포된 Lambda 함수에서도 호출할 수 있으며, 이를 통해 웹에서 미디어 데이터 스트리밍 API 를 구현하여 인터넷 접속을 통해 실시간 스트리밍 영상을 볼 수 있도록 구현할 수 있다.

## G. 결론 및 추후 연구

### A. 연구 결과

구현했던 시스템의 초기 버전에는 문제점이 몇 가지 존재했다. 모델 추론의 정확도가 다소 떨어진다는 점과 스트리밍의 지연시간이 4~5 초정도로 상당한 시간의

지연이 생기는 것과 초당 프레임 수가 3~4 회로 매우 낮다는 점이다. 이러한 문제점을 바로잡기 위해 이미지 데이터와 코드를 조금씩 수정하여 수십번의 빌드를 거쳤다.

#### 1) 모델 추론 정확도 향상

초기 버전에는 약 200 장의 이미지를 변형시켜 800 장 이상의 데이터 세트를 준비하였지만, 변형 과정에서 지나치게 회전하거나 이동된 이미지들로 인해 모델의 정확도가 크게 떨어졌다. 또한 선택한 자세 중 하나의 모양이 일반적으로 사람이 서 있는 모습과 비슷하여 높은 일치도를 출력하였다. 이를 해결하기 위해 이미지 변형률을 대폭 낮추어 진행하였으며, 새로운 라벨을 추가하고 더 나은 모델 학습을 위해 epochs 를 증가시켜 학습을 여러 번 진행하였다. 결론적으로 초기 버전보다는 나은 정확도 출력을 나타냈지만, 여전히 배경과 주위 환경에 따라 일치도 출력이 변화하는 모습을 보인다. 이는 추후 Background Substraction 등의 방법을 이용하여 개선이 필요하다.

#### 2) 스트리밍 지연시간과 초당 프레임 수와 관한 성능 향상

클라우드를 이용한 작업의 특성 상, 지연시간에 대한 문제를 완전하게 공략하기는 쉽지 않았다. 더군다나 DeepLens 가 서울 리전에 대한 서비스를 지원하지 않기 때문에, S3 스토리지와 Lambda 함수를 포함하여 모든 작업을 도쿄 리전에서 진행하였다. 초기 버전에서는 약 4~5 초의 지연시간과 초당 3~4 프레임을 나타내었다. 이를 개선하기 위해 코드를 최대한 간소화하고, 화질과 이미지 형식의 변경이 필요하였다. Lambda 함수에 화질을 설정하는 코드를 추가하여 480p 를 사용한 스트리밍을 출력하였고, 이미지 데이터 타입을 단정밀도(FP32)에서 반정밀도(FP16)로 변경하여 메모리 사용을 줄이고 데이터 전송을 빠르게 만들었다. 최종적으로 지연시간은

약 2 초 정도로 개선되었으며, 초당 프레임 수 또한 8 이상으로 증가하여 개선 효과를 얻어내었다.



[그림] 초기 모델의 plank 자세 시연 및 일치도 출력화면

### 3) 사용자와 상호작용위한 UI 변경

초기 모델의 인터페이스는 위 그림과 같이 아무 자세도 취하지 않으면 어떤 출력도 없고, 자세를 취하면 그 자세와 일치하는 라벨과 일치도만을 출력하는 방식을 사용했다. 최종적으로 빌드한 모델에서는 아래와 같이 사용자와 상호작용할 수 있도록 유저친화적인 메시지를 통해 아무 자세를 취하지 않았을 때는 “Take your pose”라는 메시지를 출력하며, 중앙에 자세를 인식할 수 있는 사각 범위를 설정하여 사용자가 자세를 취해야할 공간적 위치를 알려준다.





[그림] 어떤 자세도 취하지 않았을 때 메시지 출력



[그림] Tree 자세와 Plank 자세 시연

## B. 성능 평가

마지막 빌드에서 사용한 모델과 Lambda 함수는 이전보다 개선된 결과를 출력하였다. 배경으로 인한 간섭으로 크게 변화하던 정확도는 자세를 취했을 때 높은 일치도를 출력하였으며, 정확한 라벨 추론이 가능해졌다. 스트리밍의 지연시간 또한 상당히 개선되어 약 2 초 미만 정도로 개선되었고, 초당 8~9 프레임의 영상을

출력하였다. 또한 사용자 인터페이스 환경을 개선하여 인식 가능한 사각 범위를 보여주고, 자세를 취하지 않았을 때는 자세를 취해달라는 메시지를 출력한다.

### C. 결론

그림과 같이 자세를 취했을 때, 자세의 일치도가 상단에 표시된 화면이 실시간으로 스트리밍 된다. 따라서 자신이 취해야 할 자세를 바로 피드백 받을 수 있다. 이를 바탕으로, 프로젝트를 확장하여 COVID-19 로 인해 비대면 수업 및 교육이 권장되고 있는 상황에서 비대면 수업에 제한사항이 있는 태권도, 요가와 같은 트레이닝 수업의 질을 향상시킬 수 있다. 수강생은 옛지 노드인 DeepLens 를 이용한 스트리밍으로 강 의자와 실시간 소통이 가능하며, 학습되어진 운동 자세 데이터를 바탕으로 즉각적인 자세 피드백을 받을 수 있게 되는 것이다.

### D. 추후 연구

시스템 초기 버전에 비해서는 모델 추론의 정확도와 스트리밍 지연 시간, 초당 프레임 수가 개선되었지만, 실시간 처리가 중요한 서비스인 만큼 더욱 개선해야 할 필요성이 존재한다. 모델 추론의 정확도는 Background Substraction 알고리즘을 이용하여 개선시키는 것을 고려한다. 또한 스트리밍에 관해서는 로그를 남기는 코드와 같은 불필요한 부분을 제거하거나, DeepLens 와 통신하는 SageMaker Job 을 저장하는 S3 스토리지 혹은 실행되는 Lambda 함수를 서울 리전에서 실행시키는 방법을 고려하는 것이 필요하다.

이러한 시스템은 추후 다양한 서비스에서 활용될 수 있다. 요가, 태권도 강의 등 뿐만 아니라 실시간 처리가 중요한 모든 딥러닝/스트리밍 시스템에서 모델 추론의 정확도를 높이고, 스트리밍의 품질을 개선시킬 수 있는 방법을 제의할 수 있다.

## H. 참고 문헌

- [1] AWS DeepLens : <https://aws.amazon.com/deeplens/>
- [2] DeepLensCommunity Project: <https://aws.amazon.com/deeplens/community-projects/>
- [3] AWS DeepLens 설명서 : <https://docs.aws.amazon.com/deeplens/index.html>
- [4] 강태욱, 인공지능 비전 장치 아마존 딥렌즈 (2019/7, AD&Graphics)